

01 / PROBLEM

真实问题：评测结果存在，但不能稳定支撑模型决策与发版

问题不是缺少一张榜单，而是缺少从异构评测证据到可比较结果、再到受控发布的产品链路。

OBSERVED PROBLEMS

现状中的五个断点

编号	真实现象	直接影响	需要回答
P1	Bench 各自输出 JSON、JSONL、报告或日志，字段与目录不一致	结果接入依赖人工改造，无法持续扩展	什么是所有 Bench 真正共享的最小协议？
P2	模型名、Deployment、Thinking 与版本散落在运行配置中	同名模型无法稳定追踪；新模型容易遗漏配置	模型与一次 Run 应如何关联？
P3	执行失败、质量低分、Judge 失败和重试混在同一 success / failure 中	成功率、分母和重跑口径失真	错误、Repeat、Retry、Rerun 如何区分？
P4	榜单直接消费快照或聚合文件，重跑与修正可能覆盖历史	无法解释某次发榜依据，也无法安全撤榜	执行证据与发布状态如何解耦？
P5	质量、Token、Latency、成功率缺少统一展示规则	模型选型只看到分数，看不到成本与可靠性	哪些指标参与排名，哪些只辅助决策？

RESEARCH DESIGN

两条调研线：先确定产品判断，再确定技术边界

调研线	编号	重点问题	产出
产品调研	P-R1	主流榜单怎样组织字段、分榜与信息层级？	Viewer 的页面结构与选型字段
产品调研	P-R2	内部中台与公开榜单的任务差异是什么？	首页密度、信息优先级与交互取舍
产品调研	P-R3	谁运行、审核、发榜和撤榜？如何控制账号？	Publisher 工作面、角色和状态流
技术调研	T-R1	哪些对象和字段能跨 Runner 稳定成立？	最小协议、扩展与 Bench Policy
技术调研	T-R2	失败、重跑、版本与可比性如何表达？	Registry、Validator 与 Comparison Group
技术调研	T-R3	证据、榜单状态与审计如何解耦？	Run / Result / Artifact 与 Publication Event

研究完成口径

产品调研回答“用户先看什么、如何完成任务、哪些能力不应照搬”；技术调研回答“数据如何可信、可比、可追溯”。两条线最终必须汇合到同一页面、流程与数据边界。

02 / PRODUCT RESEARCH

三类 Benchmark 产品，三种侧重点

只看与评测中心最相关的三个项目：OpenCompass 侧重快速选型，HELM 侧重可信解释，OpenBench 侧重把评测稳定跑起来。

OVERVIEW

定位、影响力和组织方式

01	OpenCompass / 司南	综合模型榜单
定位与概况：面向开发者和研究者的综合模型评测入口。公开 LLM 页聚合 134 个模型，分能力、安全、特色三类榜单；能力榜再区分官方评测、开源评测和竞技场投票。影响力：覆盖 OpenAI、Anthropic、Google、DeepSeek、Qwen 等主流模型，是国内常用的横向选型参考。组织方式：模型为行，发布日期、参数量、均分及知识 / 推理 / 数学 / 代码为列；用户先在必选榜单筛选模型，再看单项能力与评测规则。它把“总榜定位—分榜判断—单 Bench 解释”放在同一浏览链路。		
02	HELM	研究型 Benchmark
定位与概况：Stanford CRFM 推出的透明评测框架与榜单，重点不是给一个总排名，而是说明模型在什么 Scenario、Metric 和配置下得到结果。影响力：在学术与研究社区中代表“可复核评测”的做法。组织方式：Scenario 定义任务与数据分布，RunSpec 固定模型适配、指标和运行条件，多个 Run 组成 Suite，再形成版本化 Release；榜单 Cell 可下钻到请求、响应和单实例指标，因此聚合分数与原始证据之间没有断层。		
03	Groq OpenBench	评测工程基础设施
定位与概况：建立在 Inspect AI 上的 Benchmark suite、发现机制和 CLI，本身更像评测接入层而非大型公众榜单。影响力：价值主要在工程组织——展示了怎样复用成熟 Runner，而不是重建执行引擎。组织方式：BenchmarkMetadata 负责名称、说明与发现，Inspect Task 负责 Dataset / Solver / Scorer，EvalLog 保存逐样本结果、错误、分数与 Usage；导出到 Hugging Face 只是共享和展示投影，不取代原始运行记录。		

TAKEAWAYS

学什么，不学什么

产品	学什么	不学什么
OpenCompass	能力总榜、场景榜、单 Bench 共用浏览逻辑；模型版本 / Thinking 与分项同屏；均分旁显示覆盖率	不复制公众站 Hero 和运营内容；不把不可比 Bench 生硬平均；Token / 延迟只辅助选型，不混入质量分
HELM	Benchmark 版本、Comparison 条件和主指标写清；聚合结果能追到 Run、Result、样本与 Artifact	不把全量 Scenario × Metric 矩阵搬到首页；不要求已有内部 Bench 改写成 HELM 对象体系
OpenBench	保留各 Bench 原生 Runner；用轻量 Registry + Adapter 接入；逐样本记录失败、Retry、Token 与 Latency	不把 EvalLog / 导出文件当在线真源；导入成功不等于正式发布；不以框架版本代替可比规则

CONCLUSION

综合结论：三者拼起来，仍缺少内部发版闭环

OpenCompass 解决“怎么看”，HELM 解决“怎么解释”，OpenBench 解决“怎么跑”；三者都没有覆盖内部团队的完整职责链：评测负责人运行候选，Publisher 审核并发榜，Viewer 用正式结论选型。内部产品不需要大 Hero 和社区运营入口，需要把榜单、覆盖率、成本、失败和追溯按决策优先级排在首屏，并让发布 / 撤榜成为受控操作。

MINIMUM SOLUTION

最小实现只补四个空档

- 看结果：Viewer 首页看 Bench 状态；详情页看 Overview、排名、维度、成功率、Token / Execution 与 Latency p50；模型页给能力总榜、场景榜、覆盖率和各 Bench 分数。
- 持续评测：Publisher 版本化登记 Model / Deployment / Thinking 与 Benchmark，选择 Model × Bench 执行；Adapter 校验后写入 Draft，导入成功不自动上榜。
- 发布治理：审核页核对分数、失败样本、运行上下文和 Artifact 后 Publish；异常时 Retract / Restore；每次动作追加 actor、time、reason，证据不被改写。
- 数据与权限：独立 Next.js App；PostgreSQL 保存可查询与审计对象，OSS 保存大型输入输出和日志；角色仅 viewer、publisher、disabled，未授权访问返回 404。

03 / TECHNICAL RESEARCH

R1–R2：数据对象与最小公共协议

外部项目普遍存在 Benchmark、Run、Sample、Score 和 Artifact，但没有共同的完整内部模型。

R1 · DATA OBJECTS

五类对象：统一关系，不复制实现

对象	代表项目做法	跨项目观察	首版落点
Benchmark	Inspect Task；HELM Scenario + RunSpec；OpenAI EvalSpec	都需要稳定任务身份，内部定义不相同	benchmark_id@benchmark_version 唯一；评分定义由 Bench 版本化
Run	Inspect / MLflow 有一等 Run；HELM 使用 Run 目录	Run ID 对聚合、重跑与审计稳定有用	run_id + Benchmark 引用 + 基础时间进入 Core
Sample / Result	Inspect 分开 sample、epoch、execution UUID、retry	逻辑题目、重复实验、执行和重试不是一回事	case_id 表示题目；result_id 表示一次执行
Score	Inspect 支持标量 / 序列 / 映射；HELM 区分样本与聚合	没有统一 Score 形状；样本分与榜单指标不同层	公共 metrics 开放；单位、方向、聚合由 Policy 定义
Artifact	EvalLog、Run 目录、event JSONL、Trace、Artifact URI	共同点是结果能回到证据，而非统一文件格式	允许 path / URI；首版不冻结 MIME、checksum 和后端

R2 · PROTOCOL BOUNDARY

最小协议只负责读取、关联与校验

层级	包含	边界
Core	Schema、Benchmark / Run / Result ID 与引用、基础时间、execution_status	必须可读、可关联、可校验；不决定评分、公平性或发布资格
Optional Extension	Dataset / Scorer / Model / Code / Runtime / Thinning / Token / Trace	可记录但并非所有 Preview 都能提供；缺失不使 Core Bundle 非法
Bench Policy	Dataset、Rubric、Metric、Repeat、N/A、失败分母、可比条件	由具体 Bench 版本化；不写进公共 Validator
Leaderboard Policy	Comparison Group、主指标、单位 / 方向、排名、发布与撤榜	由产品层执行；不修改 Runner 事实
Derived	样本数、成功率、分位数、Token / 成本汇总	聚合器计算；发布记录保存聚合器版本与结果引用
Deferred	跨 Bench failure taxonomy、通用 Attempt、强 Artifact manifest	等待更多真实 Bench 证据，避免过早冻结

R1–R2 结论

采用 Benchmark → Run → Result → Score / Artifact 的追溯关系和开放扩展；拒绝复制任一项目的 EvalLog、数据库或完整 Trace 模型，也不让公共 Validator 承担 Bench 业务规则。

04 / TECHNICAL RESEARCH

R3–R4：失败语义、Registry 与可比性

协议合法、结果可比和允许发布是三种不同判断；错误恢复也不能改变计划样本数。

R3 · FAILURE & RERUN

六个容易混淆的概念

概念	回答的问题	首版规则
质量失败	执行完成，但答案低分或未通过？	正常 Result + Bench Score；不标记为执行错误
执行错误	调用、解析、渲染或基础设施未完成？	execution_status=error；保留开放 error 与 Artifact
Repeat	Bench 是否主动重复采样？	可选 repeat_index；计入实验样本设计
Retry / Attempt	同一次执行是否因瞬时错误恢复？	可选 lineage；不增加计划样本数
Rerun	修复后是否重新执行？	新 run_id；不覆盖旧 Run
N/A / 分母	哪些结果参与质量、可靠性或 Judge 统计？	由 Bench / Comparison Group 声明并在 UI 展示

R4 · REGISTRY & COMPARABILITY

合法、可比、可发布必须分层

判断	负责组件	执行规则
能否发现	Registry	扫描或显式输入 Benchmark；benchmark_id@version 去重；返回 entries + issues
协议是否合法	Validator	只检查 Schema、引用、重复 ID 和基础时间；失败不代表模型能力差
结果是否可比	Bench + Leaderboard	同 Benchmark 版本是必要条件；满足 Bench 声明后进入同一 comparison_group
能否默认排名	Leaderboard	同组、主指标可用、分母一致；缺组结果只能展示
能否发布	Publisher workflow	通过 Validator 与 Bench Policy 后仍需人工审核；导入结果默认为 Draft

COUNTER-CHECK

真实 Bench 证明不能使用全局分母或固定失败枚举

Bench	真实差异	对协议的影响
Formal-100	多轴、worst-of、N/A、压力项；Latency 不进内容分	评分、Repeat 与分母必须属于 Bench Policy
Slide Layout	generation / render / judge 多阶段失败；attempts 独立	公共 error 保持开放；原生日志作为证据
In-class	一个 Run 可有多个 Target；target / judge / aggregate 分开	candidate 由 Entry 承接；质量与可靠性分母分开

05 / TECHNICAL RESEARCH

R5–R6 : Leaderboard、Release 与审计

榜单展示的是满足比较规则且被人工发布的 Entry；发布状态不能反向改写运行证据。

R5 · LEADERBOARD

比较、排名和指标展示

证据	观察	采用	不采用
HELM	Suite / Release 组织可比较的 RunSpec 与指标	显式 comparison group；比较边界可追溯	不从底层字段全等自动推断公平性
OpenBench	按 Benchmark 分组并聚合统计	按 Bench 排名；主指标与维度分开	不默认把全部 Bench 压成一个总分
Langfuse / MLflow	Dataset、Scorer、Model 版本形成实验上下文	保存 provenance；由 Bench 决定哪些版本影响可比性	不把所有 provenance 设为 Preview Core 必填
OpenMAIC UI	选型同时关注质量、可靠性、Token 与延迟	质量、成功率、Token / Execution、Latency p50 分开展示	效率指标不改变质量排名；缺失不伪造为 0

R6 · PUBLICATION

发布、撤榜与恢复是追加式事件

事件	展示结果	数据与审计规则
Draft	不进入 Viewer 榜单	导入或新评测默认状态；保留 Run / Result / Artifact
Published	进入对应 Bench 与 comparison group	新增 published event，记录 actor、timestamp、reason、Entry / Run
Retracted	从当前榜单移除	新增 retracted event；不删除或修改 Run、Result、Score、Artifact
Restored	重新进入榜单	新增 restored event；保留完整事件链
Invalid	不可恢复地排除当前 Entry	仍保留事实证据；修复后使用新 Run / Entry，而非覆盖

DECISION TRACE

六项调研的合并结论

结论	必须采用	明确拒绝或延后
D1	最小 Bundle + Adapter；Benchmark / Run / Result / Artifact 可追溯	复制完整 Runner Schema；统一 Score 形状；强 Artifact manifest
D2	协议合法 ≠ 可比 ≠ 可发布；Comparison Group 承担公平边界	Validator 判断发布资格；所有配置字段全等；无组默认排名
D3	失败不丢失；Retry 不增样本；Rerun / Rejudge 不覆盖历史	统一失败分母；单一 success / failed；预设复杂 taxonomy
D4	不可变证据 + 追加式 Publication Event	撤榜删除结果；发布状态写入 Run；仓库生产 snapshot 作为真源

06 / FINAL DECISION

最终架构：独立 App + PostgreSQL + OSS

独立 App 提供清晰产品边界与发布节奏；PG 承担结构化真源；OSS 承担大型原始证据。三者职责不可互换。

WHY THIS ARCHITECTURE

技术选择与被拒绝方案

方案	优点	主要问题	结论
仓库 snapshot + 静态前端	快、易演示、无需服务端	生产结果重复提交；难以查询、权限控制、幂等导入与审计	拒绝作为产品架构
通用实验追踪平台	Run / Trace / Artifact 能力成熟	缺少 Benchmark、Comparison Group、Leaderboard 与发布治理语义	只借鉴数据分层
独立 App + PG + OSS	产品边界清晰；可独立迭代部署；结构化查询与大数据对象分离	需要单独维护部署、SSO 集成和服务端权限	最终采用

ARCHITECTURE

页面到接口、服务、数据库和证据存储

01 独立 Next.js App Viewer / Publisher UI 与 Route Handlers	02 Auth & API MAIC SSO 回跳 + Evaluation Role guard	03 Domain Service 查询、导入、候选编排、发布状态机	04 PostgreSQL 结构化 source of truth：排名、筛选、审计	05 OSS + Runner 输入输出、Trace、日志、图片 / PPT / 视频
---	--	---	---	--

STORAGE BOUNDARY

三类数据分别放在哪里

位置	保存	约束
App repository	页面、API、Schema、migration、Registry 配置、Adapter / CLI	不提交完整生产结果、凭证或大型 Artifact
PostgreSQL	Benchmark、Run、Result、聚合指标、Comparison Group、Entry、Event、权限与导入批次	可查询字段正常列；Bench 可选扩展可用 JSONB；禁止整份 snapshot 单行存储
OSS	完整输入输出、Trace、运行日志、截图、PPT、视频和其他大数据对象	PG 只保存 object key、hash、size、MIME、脱敏状态；客户端不持有长期 AK

DEPLOYMENT & ACCESS

独立 App 的运行边界

关注点	实现	约束
部署	独立构建、域名、环境变量与发布流水线	产品可独立发布；不依赖主站前端路由
身份	复用 MAIC SSO 的登录跳转与 return URL	不复制账号库；只消费稳定 user_id
授权	Evaluation 专属 viewer / publisher 角色；页面与 API 同时服务端校验	未登录跳 SSO；无权限或关闭环境返回 404；noindex 不是鉴权
数据访问	App 服务端访问 PG / OSS；Runner 通过受控 import / ingestion 写入	浏览器不直连 PG / OSS；开发者不持有长期 OSS AK

架构结论

独立 App 是最终产品与部署边界；PostgreSQL 是唯一结构化真源；OSS 是原始证据存储。文件 Bundle 只作为 Runner 与平台之间的交换格式，不作为在线页面的数据源。

07 / PRODUCT SOLUTION

完整闭环：从 Registry 到评测、审核和发版

Viewer 与 Publisher 共用同一数据底座；新模型和新 Benchmark 通过不同入口进入同一 Draft → Published 状态流。

PRODUCT SURFACES

两个角色，五类页面

页面	主要任务	关键规则
登录 / Access	SSO 登录、原路径返回、角色判断	无权限返回 404；不设置公开导航入口
Leaderboard	能力总榜、场景榜、单 Bench 排名	只读取 Published Entry；跨组不默认比较
Benchmark Detail	Overview、维度、质量、成功率、Token、Latency、来源	缺失 / N/A / error / 低分分开；指标口径可解释
Model Directory	模型版本、Deployment、Thinking、Bench 覆盖与详情	Registry 只保存身份和路由，不保存分数、凭证或结果 snapshot
Publisher Console	候选执行、Draft 审核、Publish / Retract / Restore、审计	publisher 专属；每个状态变化必须填写原因

WORKFLOW A

新增模型并持续评测

步骤	操作	产物	门禁
1	登记 Model Version、Deployment、Thinking 与公开元数据	版本化 Model Registry 条目	字段、引用、唯一性、敏感信息校验
2	选择 Model × Benchmark，执行 compatibility → smoke → full-lite	新 Run、逐 Case Result、Artifact	失败保留；Retry 不增样本；Rerun 不覆盖
3	导入 PG 并生成 Draft Entry	可查询但未发布的候选	幂等导入；同 ID 异内容事务回滚
4	人工查看指标、失败样本与证据并发布	Published Entry + publication event	服务端 Publisher 权限 + reason

WORKFLOW B

新增 Benchmark 与撤榜 / 恢复

流程	操作	结果
新增 Benchmark	登记 benchmark_id@version、层级、场景、主指标 → 编写 Adapter → 校验 Bundle → 定义 comparison group	复用同一 PG、OSS、权限与发布能力；Bench 自己负责评分和分母
撤榜	选择 Published Entry → 填写原因 → Retract	Viewer 即时移除；Run / Result / Artifact 不变；追加审计事件
恢复	选择 Retracted Entry → 填写原因 → Restore	重新进入原 comparison group；追加事件，不改写旧事件

08 / TECHNICAL APPENDIX

Schema、指标、验证与实现状态

本页区分目标架构、已实现代码和仍需真实环境验收的部分，避免把本地 Demo 等同生产交付。

POSTGRESQL SCHEMA

实际九张表与非表对象

表 / 对象	职责	说明
evaluation_benchmarks	Benchmark 身份、版本与展示元数据	Bench Policy 可放结构化列与有限 JSONB
evaluation_runs	一次运行、候选 provenance 与时间	Rerun 新建；不保存发布状态
evaluation_results	逐 Case 执行状态、Score 与 usage	Result ID 唯一；错误和质量分离
evaluation_comparison_groups	可比性与排名边界	同组 Entry 才默认横向排名
evaluation_entries	Run / candidate 的榜单投影与派生指标	导入默认 Draft；当前状态由事件投影
evaluation_publication_events	发布、撤榜、恢复、判无效	append-only；actor / time / reason
evaluation_artifacts	OSS object key、hash、size、MIME、脱敏状态	完整证据不写入 PG
evaluation_import_batches	幂等导入、fingerprint、冲突和回滚	重复数据跳过；同 ID 异内容拒绝
evaluation_user_roles	viewer / publisher / disabled	复用 SSO user_id；不复制账号数据
Model Registry (代码)	模型版本、Deployment、Thinking 与执行路由	v0 不入 PG；不包含成绩、凭证或结果

METRICS

选型指标的精确定义

指标	计算	展示规则
Benchmark 主分	由具体 Bench 的 Metric / denominator policy 产生	仅同 comparison group 排名
综合参考分	正式 eligible Bench 先按场景等权，再对完整场景等权	后续产品规则，不属于公共协议；覆盖不完整显示 —
Token / Execution	仅成功且有 usage 的执行求平均；失败、timeout、缺失不进分母	可排序，不参与质量计分；无有效样本显示 N/A
成功率 / Latency	completed / planned；成功执行 latency p50	与质量分独立；任何最终失败均保留 Result

VERIFICATION STATUS

证据强度与剩余验证

部分	已有证据	仍需验证
Protocol	Schema / Registry / Validator 与回归测试已完成	随更多真实 Adapter 复核 v0 → v1
PG / Import	migration、幂等重复导入、同 ID 冲突回滚已有自动化与本地 P G 验证	受控环境执行正式历史数据导入
Query / Publication / UI	服务、权限、published-only、发布状态机与页面已有代码和本地验证	部署域名下使用真实 SSO 账号、角色与 OSS 权限做 E2E
Continuous evaluation	Model Registry、候选命令和 In-class 路径已有实现；作品集 D emo 展示完整交互	真实供应商执行、更多 Bench Adapter 和生产调度按需扩展